MACHINE LEARNING

CASO 1.3 Credit Risk Scoring (Finanzas)

Colque Murillo Ivonne Micaela
Mamani Pamuri Dilan Obed
Pérez Dick Tania Morelia
Retamozo Torrez Ignacio
Rocha Vedia Adriana Nathalie
GATOBYTE

1. ENTENDIMIENTO DEL NEGOCIO Y DE LOS DATOS

1.1. Contexto del Caso

El análisis de riesgo crediticio es una de las tareas más importantes dentro del sector financiero, ya que permite a las entidades evaluar la probabilidad de que un cliente cumpla o no con sus obligaciones de pago. Cuando una institución financiera otorga tarjetas de crédito, asume un riesgo asociado al comportamiento futuro de los clientes. Si este riesgo no se gestiona adecuadamente, puede generar pérdidas económicas debido al incumplimiento de pagos o a una mala estimación del flujo de dinero que los clientes devolverán al banco. Por esta razón, muchas instituciones utilizan técnicas de análisis de datos y aprendizaje automático para anticipar el comportamiento financiero de los clientes y mejorar la toma de decisiones.

En este contexto, el presente caso de estudio utiliza un dataset proveniente de clientes de tarjetas de crédito en Taiwán durante el año 2005, el cual contiene aproximadamente 30,000 registros. Este conjunto de datos incluye información demográfica, financiera y de comportamiento de pago de los clientes, lo que permite analizar factores que pueden influir en su comportamiento financiero, como el límite de crédito, el historial de pagos y otras características relacionadas con el uso de la tarjeta.

1.2. Problema del Negocio

A partir del conjunto de datos se plantean dos problemas analíticos complementarios. El primero consiste en estimar el flujo de pago futuro del cliente, es decir, predecir cuánto pagará un cliente el próximo mes, representado por la variable **PAY_AMT**. El segundo consiste en anticipar la probabilidad de incumplimiento en el siguiente mes, representado por la variable **default.payment.next.month**, donde el valor **1** indica que el cliente entra en default y el valor **0** indica que no presenta incumplimiento.

En este contexto existen dos tipos de errores relevantes. Un **falso negativo (FN)** ocurre cuando el modelo predice que un cliente pagará, pero en realidad entra en default, lo que implica una pérdida financiera directa para la institución. Por otro lado, un **falso positivo (FP)** ocurre cuando el modelo clasifica como riesgoso a un cliente que sí pagaría, lo que representa una pérdida de oportunidades de negocio.

1.3. Objetivo General

Desarrollar un modelo predictivo que permita analizar el comportamiento financiero de los clientes de tarjetas de crédito y anticipar posibles situaciones de incumplimiento, con el fin de apoyar la toma de decisiones en la gestión de riesgo crediticio.

1.4. Objetivos específicos

- Evaluar el impacto de las variables sociodemográficas (sexo, estado civil, educación) en el desempeño del modelo, analizando posibles sesgos y documentando la decisión de inclusión o mitigación.
- Diseñar e implementar un pipeline de preprocesamiento reproducible que integre el escalado robusto de variables financieras mediante Standard Scaler y la generación de nuevas métricas de negocio, para mejorar la capacidad predictiva del modelo.
- Desarrollar un modelo de regresión baseline, evaluando su estabilidad mediante las métricas correspondientes en los conjuntos de entrenamiento y validación.
- Construir un clasificador de riesgo basado en Regresión Logística, alineado con las políticas de tolerancia al riesgo de la institución.
- Establecer un marco de interpretación de resultados que identifique las variables con mayor peso en la predicción, permitiendo generar recomendaciones accionables para los departamentos de riesgos y captación de clientes.

1.5. Variables Objetivo

En este caso de estudios, se plantean dos variables objetivo, cada una asociada a un tipo diferente de problema de aprendizaje automático.

La primera variable objetivo es **PAY_AMT**, la cual representa el monto de pago realizado por el cliente. Esta variable se utiliza para un problema de regresión, ya que su objetivo es estimar un valor numérico continuo que representa el flujo de pago futuro del cliente.

La segunda variable objetivo es **default.payment.next.month,** la cual indica si el cliente incurre en incumplimiento de pago en el siguiente mes. Esta variable se utiliza para un problema de clasificación binaria, donde el valor 1 indica que el cliente entra en default, es decir, que no pagará el siguiente mes y el valor 0 que indica que el cliente no presenta incumplimiento.

1.6. Descripción de las variables

Con el fin de describir las variables de manera más clara, estas se agrupan en dos categorías principales. La primera corresponde al perfil sociodemográfico y al crédito basal del cliente (ID, LIMIT_BAL, SEX, EDUCATION, MARRIAGE y AGE), las cuales describen las características personales del cliente y el límite de crédito otorgado.

La segunda categoría corresponde a las variables de comportamiento financiero, que reflejan el uso de la tarjeta y el historial de pagos del cliente. En este grupo se encuentran las variables PAY, BILL_AMT y PAY_AMT, que registran el estado de pago, los montos facturados y los montos pagados en distintos períodos.

• **ID:** identificador del cliente.
• **LIMIT_BAL:** límite total de crédito otorgado al cliente.
• **SEX, EDUCATION, MARRIAGE, AGE:** variables sociodemográficas del cliente.
• **PAY_0 – PAY_6:** estado de pago del cliente durante los últimos seis meses (-1 = pago a tiempo, valores positivos indican retraso).
• **BILL_AMT1 – BILL_AMT6:** montos facturados en los últimos seis meses.
• **PAY_AMT1 – PAY_AMT6:** montos pagados en los últimos seis meses.
• **default.payment.next.month:** variable objetivo que indica si el cliente incurre en incumplimiento el siguiente mes (1 = sí, 0 = no).

2. PREPROCESAMIENTO DE LOS DATOS

Con el fin de preparar el dataset para el entrenamiento de los modelos, se realizó un proceso de preprocesamiento que permitió organizar y transformar las variables de forma reproducible.

En primer lugar, los datos fueron divididos en train, validation y test utilizando **Stratified Shuffle Split**, con el objetivo de mantener la proporción original de clientes que entran en default y aquellos que no. La división utilizada fue aproximadamente 60% entrenamiento, 20% validación y 20% prueba.

Posteriormente, se generaron nuevas variables mediante feature engineering, entre las que destacan:

- **Utilization_Rate,** que representa la proporción del crédito utilizado por el cliente.
- **PAY_AMT_Total,** que corresponde al total pagado por el cliente en los últimos meses.
- **BILL_AMT_Total,** que refleja el total facturado en el mismo periodo.

Finalmente, las variables fueron organizadas según su tipo para aplicar las transformaciones correspondientes. Las variables numéricas fueron escaladas mediante StandardScaler, mientras que las variables ordinales y categóricas se mantuvieron sin transformación adicional. Todo el proceso se implementó mediante ColumnTransformer y Pipeline, lo que garantiza reproducibilidad y evita fuga de información durante el entrenamiento y la evaluación de los modelos.

3. MODELADO

El proceso de modelado se realizó mediante un enfoque comparativo, evaluando distintos algoritmos de aprendizaje automático con el objetivo de identificar el modelo con mejor capacidad predictiva y adecuada generalización.

3.1 Regresión

Para la tarea de regresión, cuyo objetivo es estimar el monto de pago futuro del cliente (PAY_AMT), se siguió una estrategia progresiva de modelado.

En primer lugar, se estableció un modelo baseline de Regresión Lineal, el cual permitió obtener una referencia inicial del desempeño del sistema. Posteriormente, se exploraron modelos capaces de capturar relaciones no lineales en los datos, utilizando Support Vector Regression (SVR).

Finalmente, se evaluaron modelos de ensamble basados en Gradient Boosting, específicamente XGBoost y LightGBM, los cuales suelen presentar un alto desempeño en problemas tabulares. Para asegurar la estabilidad de los resultados, se aplicó validación cruzada y un proceso de optimización de hiperparámetros (tuning) con el fin de mejorar el rendimiento del modelo final.

3.2 Clasificación

Para la tarea de clasificación, cuyo objetivo es predecir si un cliente entrará en default el siguiente mes, se evaluaron distintos algoritmos considerando el desbalance presente en el dataset.

Como punto de partida se utilizó una Regresión Logística sin penalización, que permitió establecer una métrica baseline de referencia. Posteriormente, este modelo fue mejorado incorporando regularización L2 y balanceo de clases, lo que permitió reducir el sobreajuste y mejorar la capacidad de detección de clientes en riesgo.

A continuación, se exploraron otros algoritmos de clasificación, entre ellos Árboles de Decisión y Support Vector Classification (SVC). Finalmente, se evaluaron modelos de Gradient Boosting, específicamente XGBoost y LightGBM, los cuales mostraron el mejor desempeño en términos de AUC.

En el caso de LightGBM, se realizó un proceso adicional de ajuste de hiperparámetros mediante RandomizedSearchCV, así como la aplicación de técnicas de regularización para reducir el overfitting. El desempeño de los modelos fue comparado mediante curvas ROC y métricas como AUC, recall, precision y F1-score.

Finalmente, se realizó un análisis de umbral (threshold) sobre el modelo LightGBM optimizado, con el objetivo de ajustar la decisión del modelo a criterios de negocio y priorizar la detección de clientes con mayor riesgo de incumplimiento.

4. EVALUACIÓN

4.1. Regresión

En la evaluación del rendimiento de los diferentes modelos se utilizaron métricas acorde a las cuales permiten analizar tanto la capacidad de discriminación del modelo como su comportamiento frente al desbalance de clases presente en el dataset. La siguiente

tabla resume el desempeño de los principales modelos evaluados en el conjunto de validación.

Modelo	RMSE	MAE	R2
Baseline - Linear	12884025981	4738829381	0.345199
SVR	12884025981	4738829381	0.345199
XGBoost Tunned	14287015569	4366619408	-0.036366
LightGBM Tunned	9100555180	2182082522	0.747964

Como se observa, el modelo LightGBM siendo probado evaluado con cambiando sus hiperparámetros fue el modelo que tuvo el mejor desempeño, alcanzando el mayor valor de RMSE, además de ser el único que obtuvo un R2 mayor al 50% por lo cual es el modelo que es capaz de explicar de mejor manera los resultados del target desde sus entradas.

4.2. Clasificación

Para evaluar el desempeño de los modelos se utilizaron diversas métricas de clasificación, entre ellas ROC-AUC, recall, precision y F1-score, las cuales permiten analizar tanto la capacidad de discriminación del modelo como su comportamiento frente al desbalance de clases presente en el dataset. La siguiente tabla resume el desempeño de los principales modelos evaluados en el conjunto de validación.

Modelo	AUC	Recall	Precision	F1
Baseline	0.7215	0.2464	0.7109	0.3660
Logística L2	0.7231	0.6209	0.4039	0.4895
Árbol de decisión	0.7440	0.5388	0.5049	0.5213
SVC	0.7620	0.5712	0.4974	0.5317
LightGBM Tuned	0.7822	0.6209	0.4782	0.5403

Como se observa, el modelo LightGBM optimizado presentó el mejor desempeño general, alcanzando el mayor valor de AUC, lo que indica una mejor capacidad para distinguir entre clientes que entrarán en default y aquellos que no.

5. INTERPRETACIÓN Y DECISIONES

El análisis de importancia de variables mostró que las características más relevantes para la predicción del default están relacionadas principalmente con el historial de pagos y el uso del crédito.

Entre las variables con mayor impacto se encuentran:

- PAY_0 y PAY_2, que reflejan el estado reciente de pago del cliente.
- BILL_AMT, que indica el nivel de facturación del cliente.
- Utilization_Rate, que representa la proporción del crédito utilizado.

Estos resultados sugieren que el comportamiento reciente de pago es el principal indicador de riesgo crediticio, lo cual coincide con los criterios utilizados comúnmente por instituciones financieras para evaluar la solvencia de sus clientes.

6. DECISIONES DEL MODELO: UMBRAL Y TRADE-OFFS

El modelo genera probabilidades de default, por lo que se evaluaron distintos umbrales de decisión con el fin de analizar el equilibrio entre recall y precisión.

Umbral	Recall	Precision
0.3	**0.8824**	0.2980
0.4	0.7415	0.3829
0.5	0.6209	0.4782

Se seleccionó un umbral de 0.3, ya que permite detectar aproximadamente 88% de los clientes que harán default, reduciendo significativamente los falsos negativos.

Esta decisión implica un trade-off: aumentar la detección de clientes riesgosos también incrementa el número de falsos positivos, es decir, clientes que podrían pagar pero que el modelo clasifica como de riesgo.

Sin embargo, desde el punto de vista del negocio, este enfoque es razonable, ya que los falsos negativos representan pérdidas financieras directas, mientras que los falsos positivos implican principalmente pérdida de oportunidades de negocio.

7. LIMITACIONES DEL MODELO

A pesar de los resultados obtenidos, el modelo presenta algunas limitaciones.

En primer lugar, el dataset presenta **desbalance de clases**, lo que dificulta lograr simultáneamente altos valores de precision y recall.

En segundo lugar, el modelo se basa únicamente en información histórica disponible en el dataset, por lo que cambios en el comportamiento financiero de los clientes o en las condiciones económicas podrían afectar su desempeño en escenarios reales.

Para agregar, durante el proceso de entendimiento de las variables se observó el ruido que generaban los **outliers** lo que dificulto entrenar los modelos.

Finalmente, algunas variables demográficas pueden no capturar completamente el perfil financiero del cliente, lo que limita la capacidad del modelo para explicar ciertos patrones de comportamiento.

8. CONCLUSIONES

El análisis realizado permitió identificar patrones relevantes en el comportamiento financiero de los clientes de tarjetas de crédito. Entre los modelos evaluados, LightGBM optimizado presentó el mejor desempeño, alcanzando el mayor valor de AUC y un equilibrio adecuado entre recall y precision.

El análisis de umbral permitió ajustar el modelo a criterios de negocio, priorizando la detección de clientes con mayor riesgo de incumplimiento. Los resultados sugieren que el comportamiento reciente de pago es uno de los principales indicadores de riesgo crediticio. En general, el modelo desarrollado puede servir como herramienta de apoyo para la evaluación de riesgo en instituciones financieras, contribuyendo a mejorar la toma de decisiones en la concesión de crédito.

9. NOTA ÉTICA

Durante el análisis del modelo se identificó un hallazgo relevante relacionado con variables sociodemográficas potencialmente sensibles, como SEX, EDUCATION y MARRIAGE. Aunque estas variables fueron incluidas en el modelo, no aparecen dentro del top 15 de variables más importantes, lo que indica que su influencia en la predicción del default es limitada.

Este resultado confirma lo observado previamente en el análisis exploratorio de datos (EDA), donde estas variables mostraban un bajo poder predictivo respecto al incumplimiento de pago.

Desde una perspectiva ética, este hallazgo sugiere que en futuras iteraciones del modelo podría evaluarse la exclusión de estas variables sin afectar significativamente el desempeño predictivo, lo que permitiría reducir el riesgo de introducir sesgos demográficos en la toma de decisiones crediticias. Como trabajo futuro, se recomienda comparar el desempeño del modelo (AUC) con y sin estas variables para evaluar su impacto real en la predicción.