CASO DE ESTUDIO 3 - GATOBYTE

Credit Risk Scoring

(Finanzas)

INTEGRANTES

- Ivonne Micaela Colque Murillo
- Adriana Nathalie Rocha Vedia
- Tania Morelia Pérez Dick
- Ignacio Retamozo Torrez
- Dilan Obed Mamani Pamuri

Entendimiento del Negocio

El análisis de riesgo crediticio es una de las tareas más importantes dentro del sector financiero, ya que permite a las entidades evaluar la probabilidad de que un cliente cumpla o no con sus obligaciones de pago. En este contexto, el presente caso de estudio utiliza un dataset proveniente de clientes de tarjetas de crédito en Taiwán durante el año 2005, el cual contiene aproximadamente 30,000 registros. Este conjunto de datos incluye información demográfica, financiera y de comportamiento de pago de los clientes, lo que permite analizar factores que pueden influir en su comportamiento financiero, como el límite de crédito, el historial de pagos y otras características relacionadas con el uso de la tarjeta.

Problema del Negocio

- Predecir cuánto pagará un cliente el próximo mes, representado por la variable PAY_AMT.
- Anticipar la probabilidad de incumplimiento en el siguiente mes, representado por la variable default.payment.next.month, donde el valor 1 indica que el cliente entra en default y el valor 0 indica que no presenta incumplimiento.

Costo de los errores:

(FN): cuando el modelo predice que un cliente pagará, pero en realidad entra en default

(FP): ocurre cuando el modelo clasifica como riesgoso a un cliente que sí pagaría

Objetivo General

Desarrollar un modelo predictivo que permita analizar el comportamiento financiero de los clientes de tarjetas de crédito y anticipar posibles situaciones de incumplimiento, con el fin de apoyar la toma de decisiones en la gestión de riesgo crediticio.

Objetivos Específicos

- Evaluar el impacto de las variables sociodemográficas (sexo, estado civil, educación) en el desempeño del modelo, analizando posibles sesgos y documentando la decisión de inclusión o mitigación.
- Diseñar e implementar un pipeline de preprocesamiento reproducible que integre el escalado robusto de variables financieras mediante Standard Scaler y la generación de nuevas métricas de negocio, para mejorar la capacidad predictiva del modelo.
- Desarrollar un modelo de regresión baseline, evaluando su estabilidad mediante las métricas correspondientes en los conjuntos de entrenamiento y validación.
- Construir un clasificador de riesgo basado en Regresión Logística, alineado con las políticas de tolerancia al riesgo de la institución.
- Establecer un marco de interpretación de resultados que identifique las variables con mayor peso en la predicción, permitiendo generar recomendaciones accionables para los departamentos de riesgos y captación de clientes.

Entendimiento de los datos

Valores faltantes

No existen valores faltantes en niguna de las columnas

Columnas y filas repetidas

0

target clasificación

default	
0	23364
1	6636

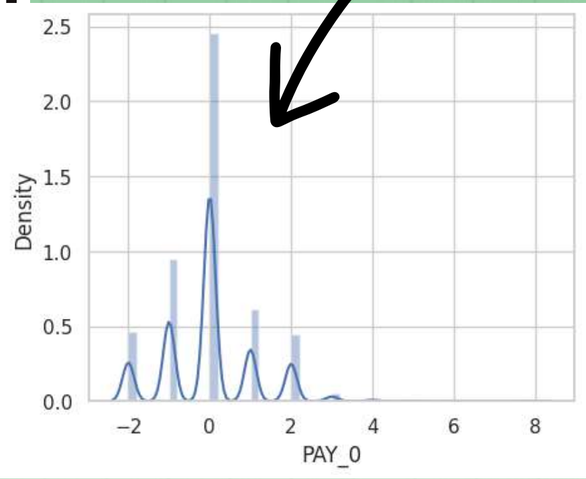

Tamaño del dataset

25 columnas y 30000 filas

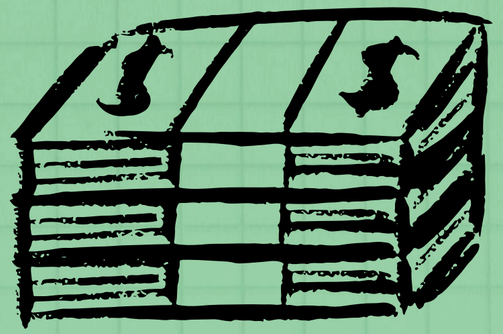

Entendimiento de los Datos

Multicolinealidad

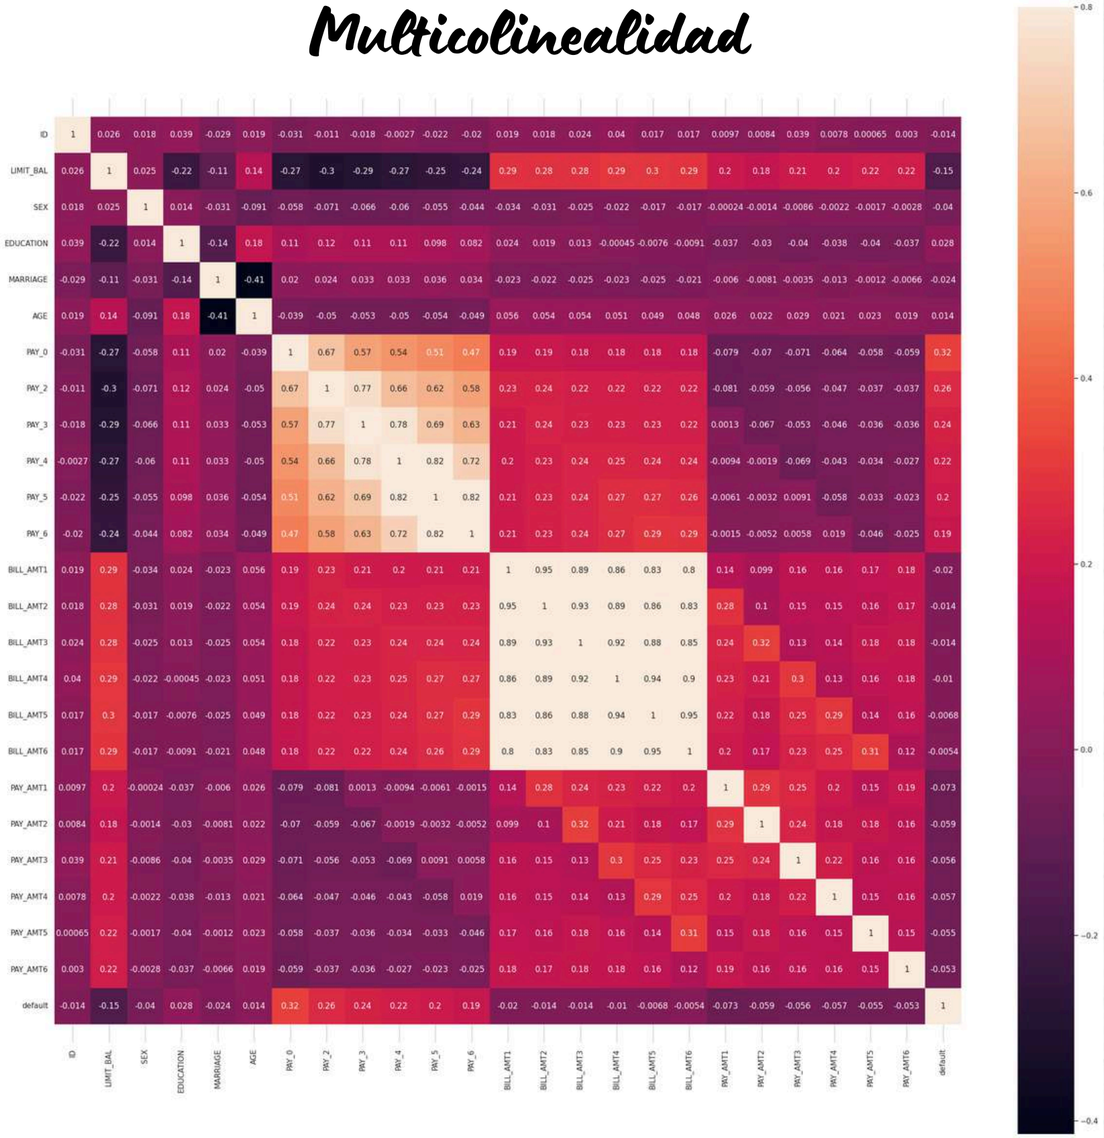

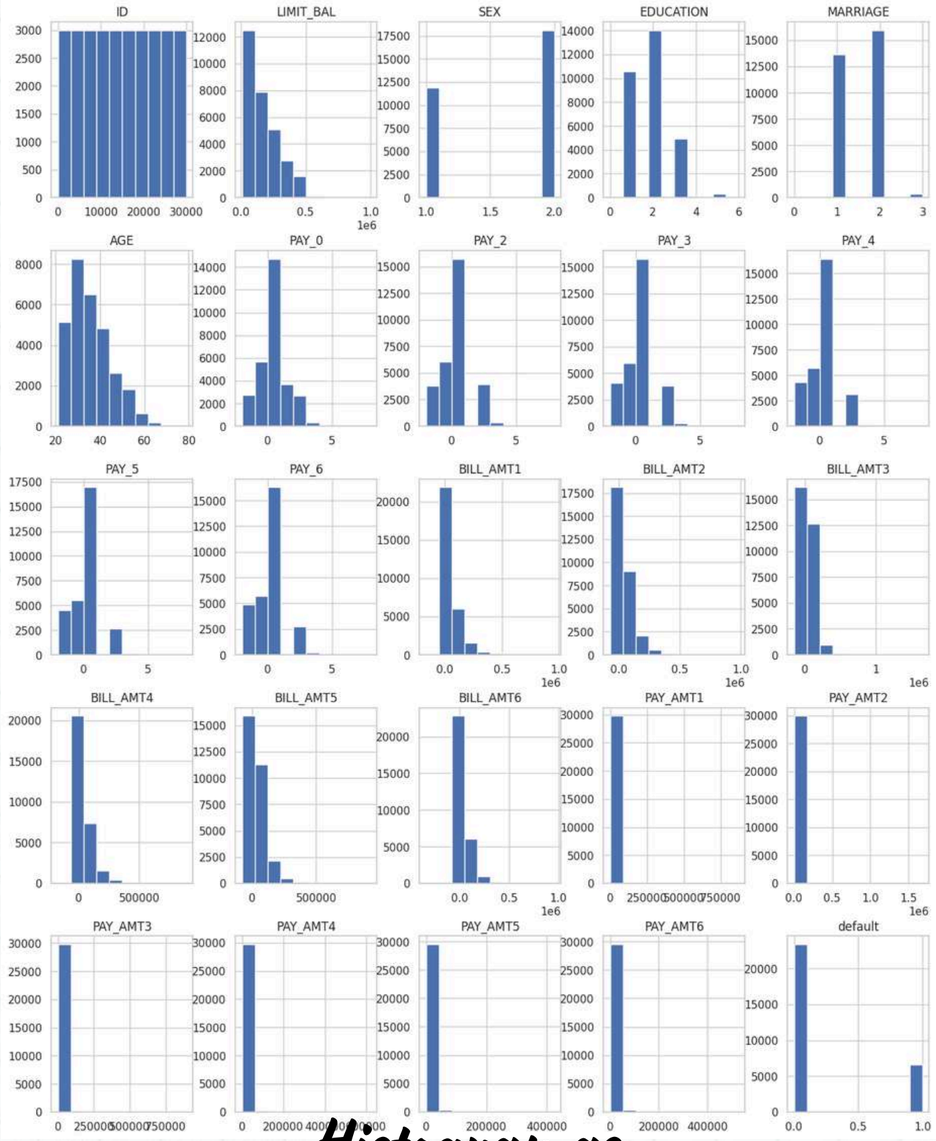

Histogramas

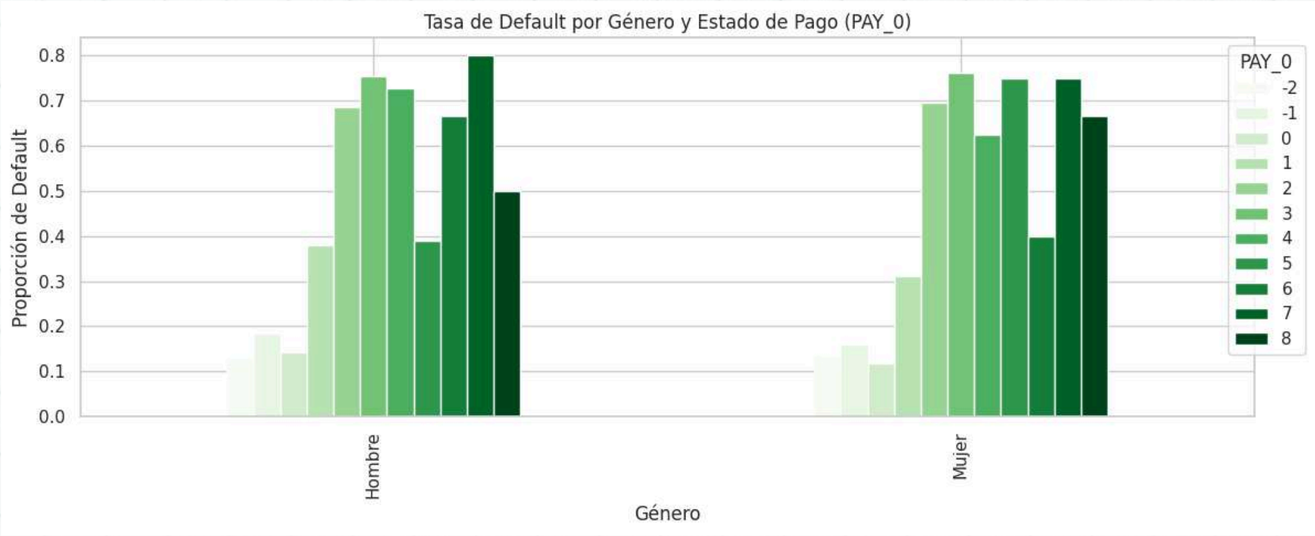

Proporción de default aumenta a medida que aumenta el retraso en los pagos (PAY_0), tanto en hombres como en mujeres.
Cuando el retraso supera uno o dos meses, la probabilidad de incumplimiento aumenta considerablemente.

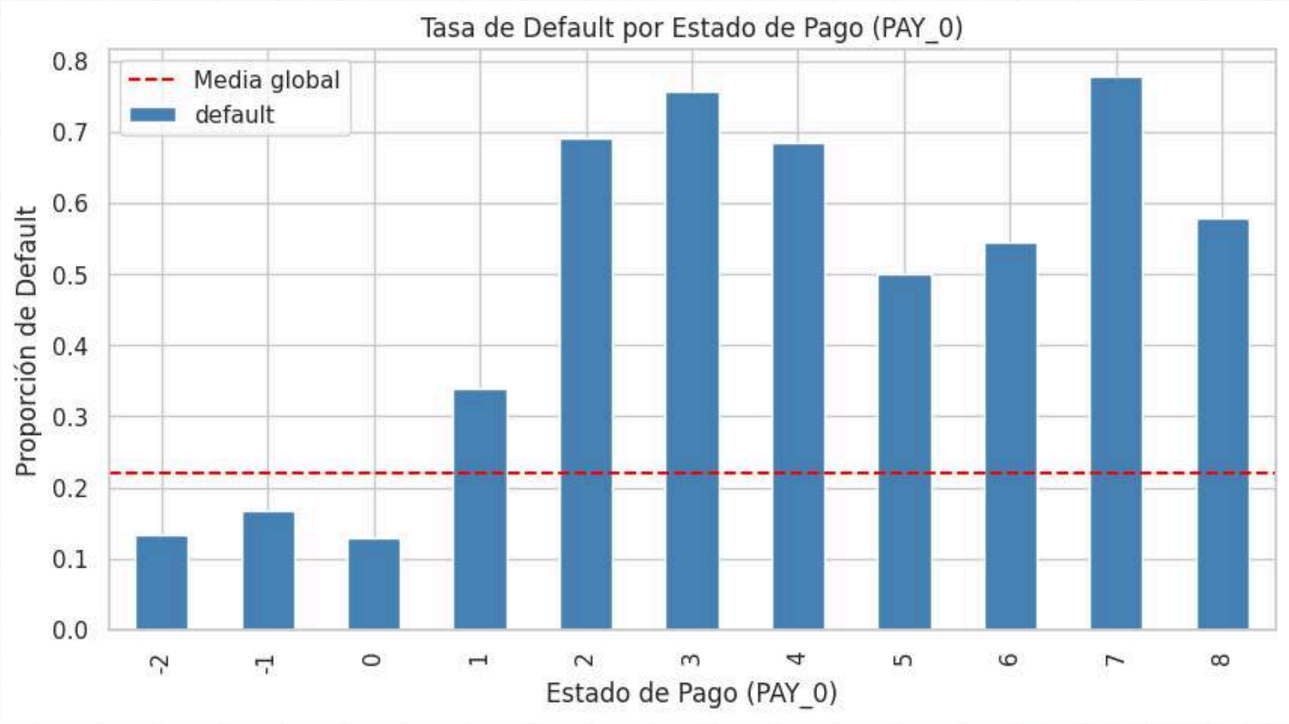

Relación clara entre el retraso en los pagos (PAY_0) y la probabilidad de default. Los clientes que pagan a tiempo o no presentan consumo (PAY_0 = -2 o -1) tienen una tasa de default baja, alrededor del 13-16%, por debajo del promedio del dataset. Cuando aparece un mes de retraso (PAY_0 = 1), la probabilidad de default aumenta a aproximadamente 34%. A partir de dos meses de retraso, la probabilidad supera el 69%, lo que indica un riesgo muy alto de incumplimiento.

Variable mas predecible de defaults.

Preprocesamiento

División del Dataset

Train: 18,000 (60%)
Validation: 6,000 (20%)
Test: 6,000 (20%)

Escalado de variables numéricas

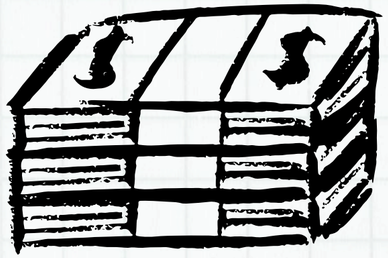

Feature Enginnering

- Utilization_Rate = BILL_AMT1 / LIMIT_BAL
- PAY_AMT_Total = suma de PAY_AMT2 a PAY_AMT6
- BILL_AMT_Total = suma de BILL_AMT1 a BILL_AMT6

Pipelines

Para evitar data leakage

Tipos de datos

Numéricos: 13
Pay status: 6
Categóricas: 3
Engineered: 3

Modelado

01 Regresion

Se determino que el mejor modelo por las distintas metricas fue LightGMB

Modelo	RMSE	MAE	R2
Baseline - Linear	12884025981	4738829381	0.345199
SVR	12884025981	4738829381	0.345199
XGBoost Tunned	14287015569	4366619408	-0.036366
LightGBM Tunned	9100555180	2182082522	0.747964

02 Clasificacion

Igualmente para la clasificación de clientes con demoras salio LightGMB

Modelo	AUC	Recall	Precision	F1	GAP
Baseline	0.7215	0.2464	0.7109	0.3660	0.0000
Logística L2 y balance	0.7231	0.6209	0.4039	0.4895	0.0053
Árbol de decisión	0.7440	0.5388	0.5049	0.5213	0.0358
SVC	0.7620	0.5712	0.4974	0.5317	0.0310
LightGBM v2	0.7810	0.6172	0.478	0.5388	0.0316
LightGBM Tuned	0.7822	0.6209	0.4782	0.5403	0.0385

Modelado Regresión

A diferencia de los demás modelos LightGBM llega atener un mejor desempeño tanto en en R2 como en ser el RMSE.
Ademas de que las predicciones son mucho mas acertadas al analizarlas con el valor real de

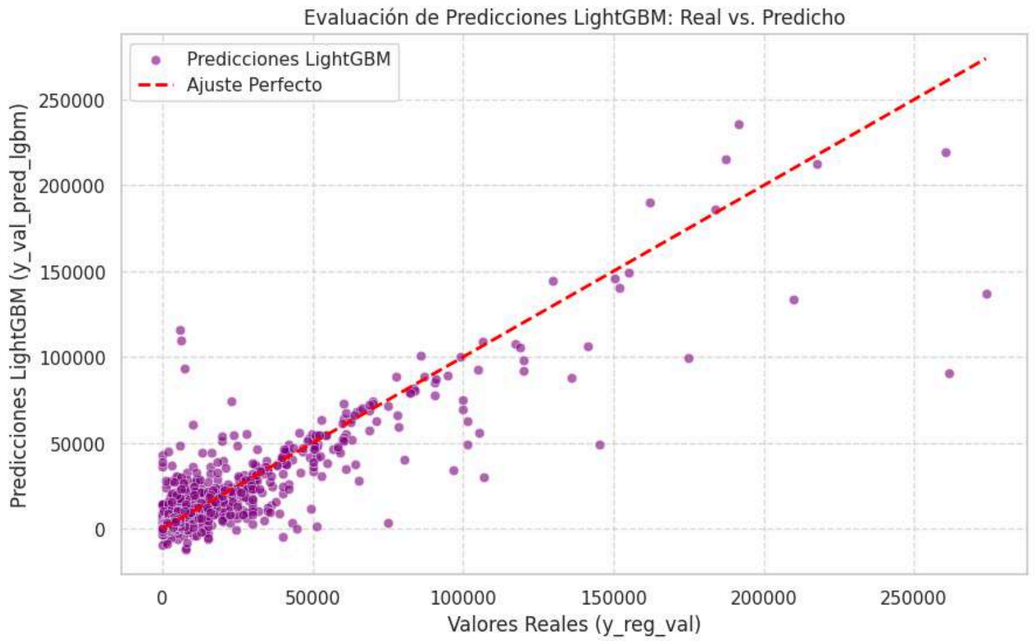

Lineal

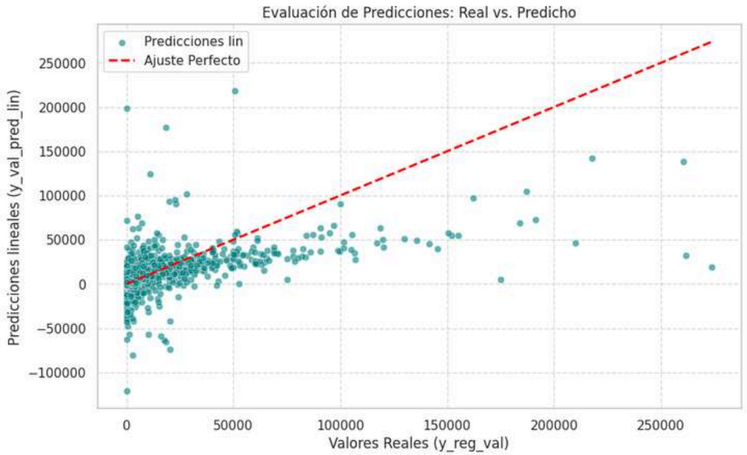

Vectores de soporte

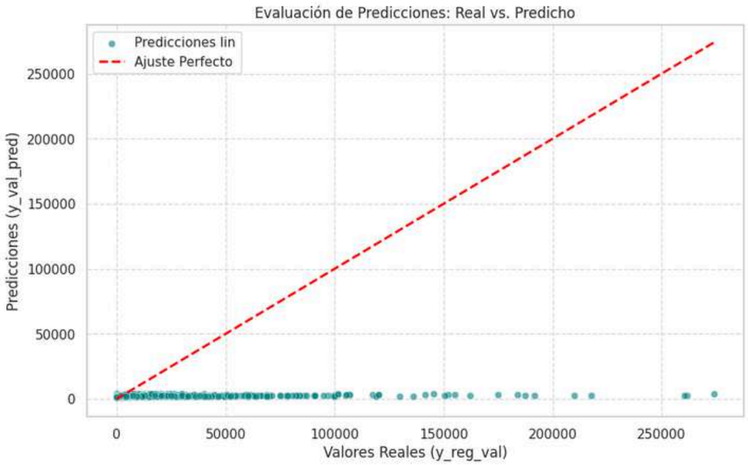

Modelado de Clasificación

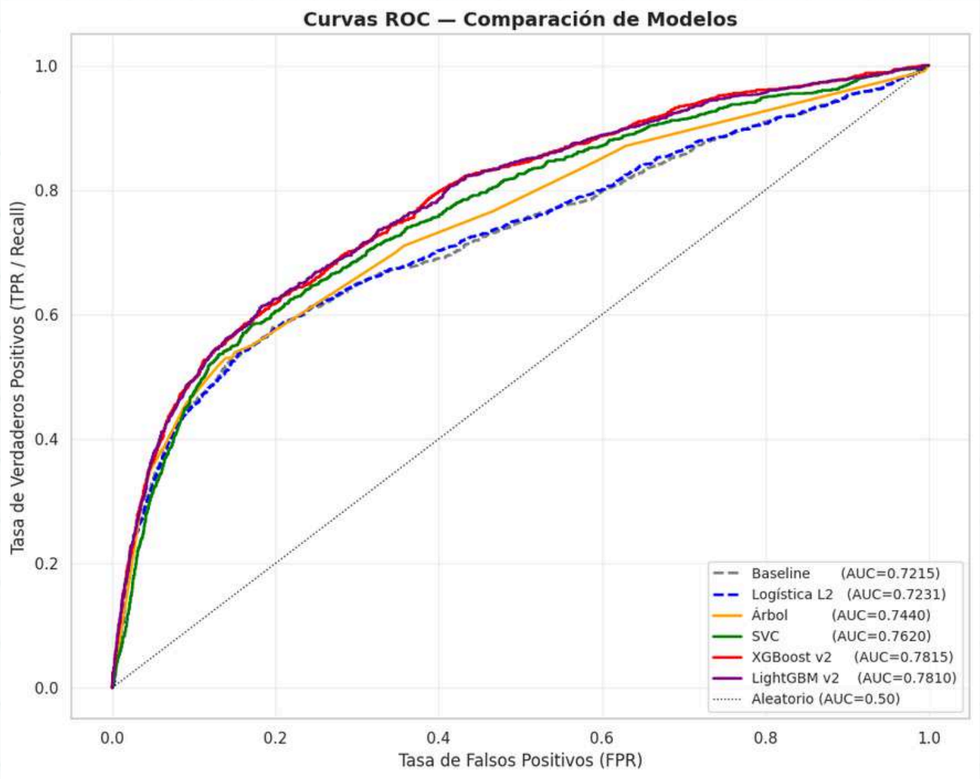

Las curvas ROC muestran que los modelos de boosting presentan el mejor desempeño, con los AUC más altos. Esto indica una mayor capacidad para distinguir entre clientes que harán default y los que no. Los modelos baseline y logística L2 muestran el desempeño más bajo, mientras que SVC y Árbol de decisión se encuentran en un nivel intermedio.

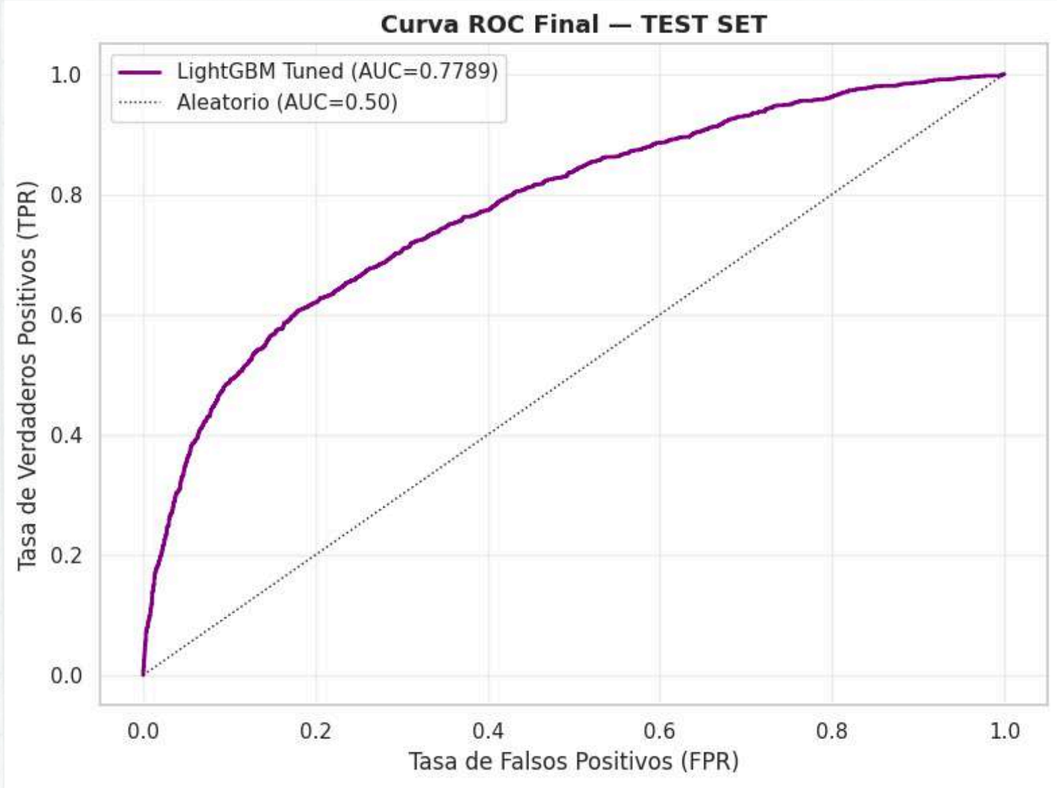

La curva ROC muestra el desempeño final del modelo LightGBM tuned en el conjunto de test, con un AUC = 0.7789, lo que indica una buena capacidad para distinguir entre clientes que harán default y aquellos que no. La curva se mantiene claramente por encima de la línea aleatoria (AUC = 0.5), confirmando que el modelo tiene capacidad predictiva significativa para el problema de riesgo crediticio.

Clasificación

Umbral	Recall	Precisión	F1	FN	FP	Política
0,2	0,9586	0,2515	0,3984	55	3786	Conservador
0,3	0,8824	0,298	0,4455	156	2759	Conservador
0,4	0,7415	0,3829	0,505	343	1586	Balanceado
0,5	0,6209	0,4782	0,5403	503	899	Growth
0,6	0,5335	0,5632	0,548	619	549	Growth

Costo estimado:

- Cada FN representa un crédito otorgado a un defaulter
- Cada FP representa un buen cliente rechazado (pérdida de negocio)

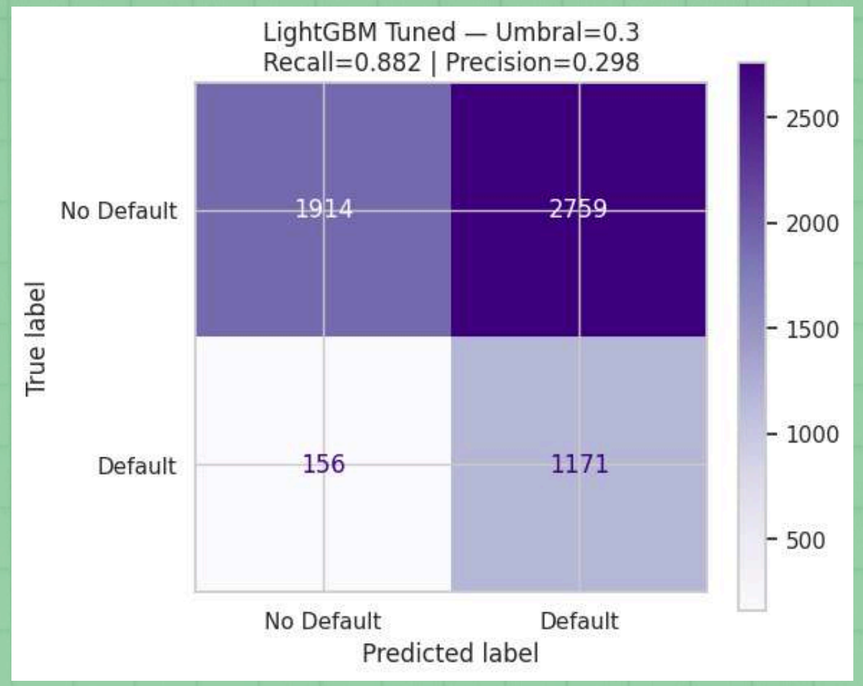

Con un umbral de 0.3, el modelo detecta 1,171 de 1,327 defaulters (recall = 0.882), reduciendo los créditos otorgados a clientes riesgosos. Sin embargo, genera 2,759 falsos positivos, lo que implica rechazar algunos clientes que sí pagarían. Este umbral prioriza la detección de riesgo crediticio sobre la maximización de clientes aprobados.

Evaluación del Modelo

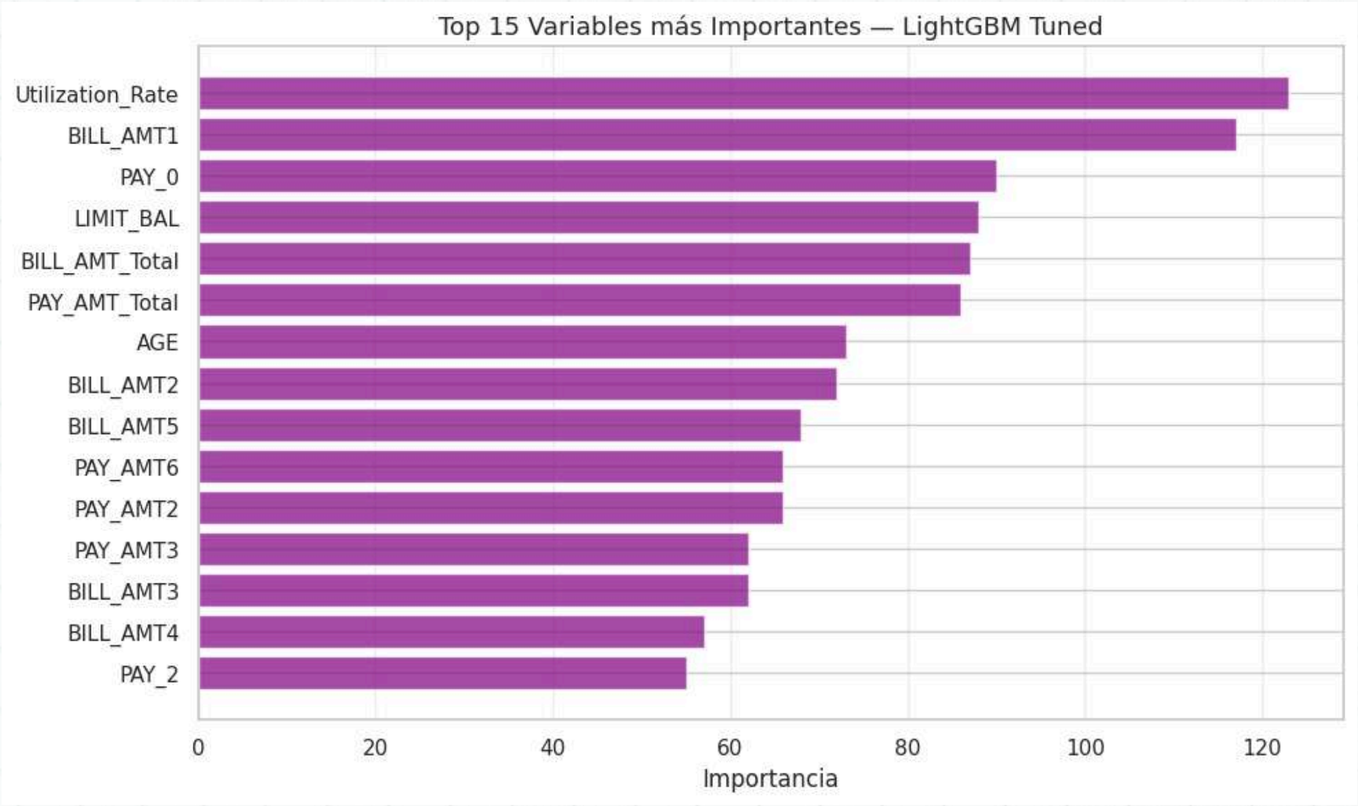

Utilization_Rate (importancia=124) : La variable engineered creada en el pipeline es la más predictiva del modelo. Confirma que la proporción del límite utilizado es el mejor indicador de riesgo crediticio. Un cliente al tope de su límite tiene alta probabilidad de default.

BILL_AMT1 (importancia=117): El saldo más reciente es el segundo predictor más importante, lo que tiene sentido ya que refleja la situación financiera actual del cliente.

PAY_0 (importancia=91): El estado de pago más reciente confirma lo visto en el EDA: un solo mes de retraso dispara la probabilidad de default. Es la variable de comportamiento más predictiva.

Evaluación del Modelo

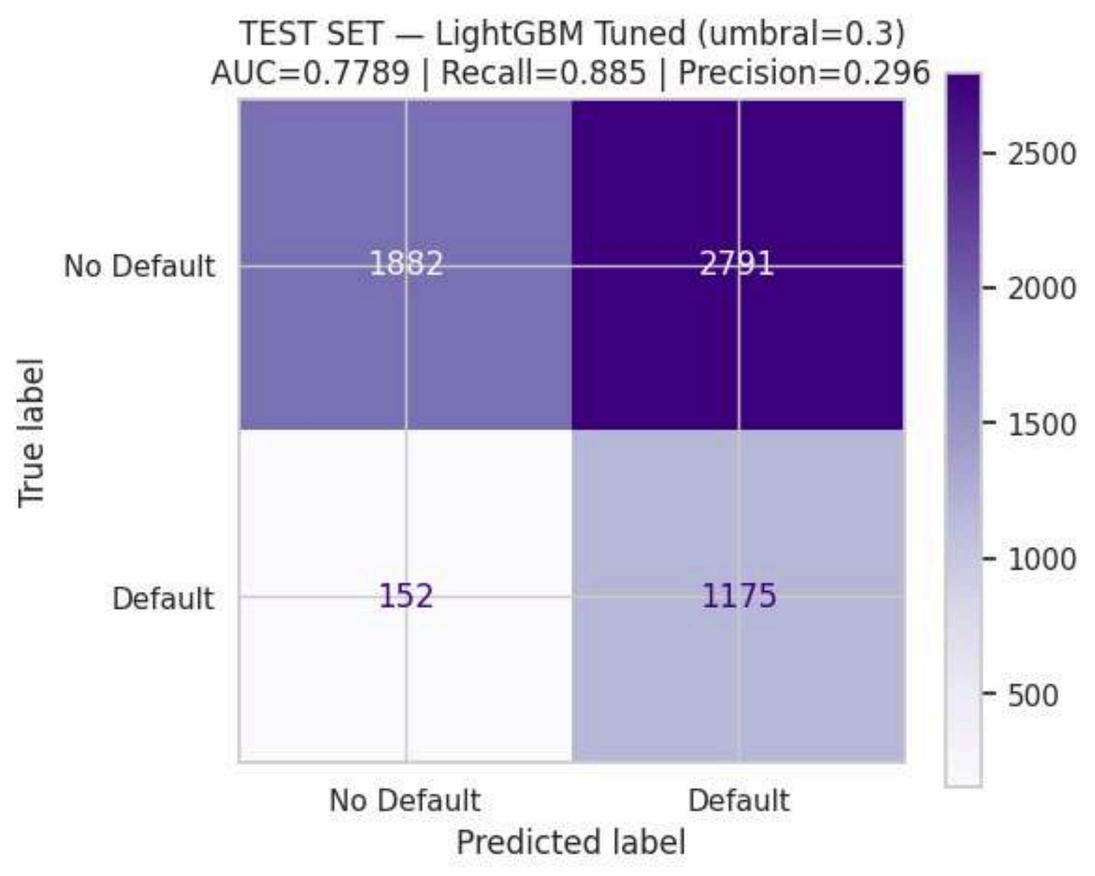

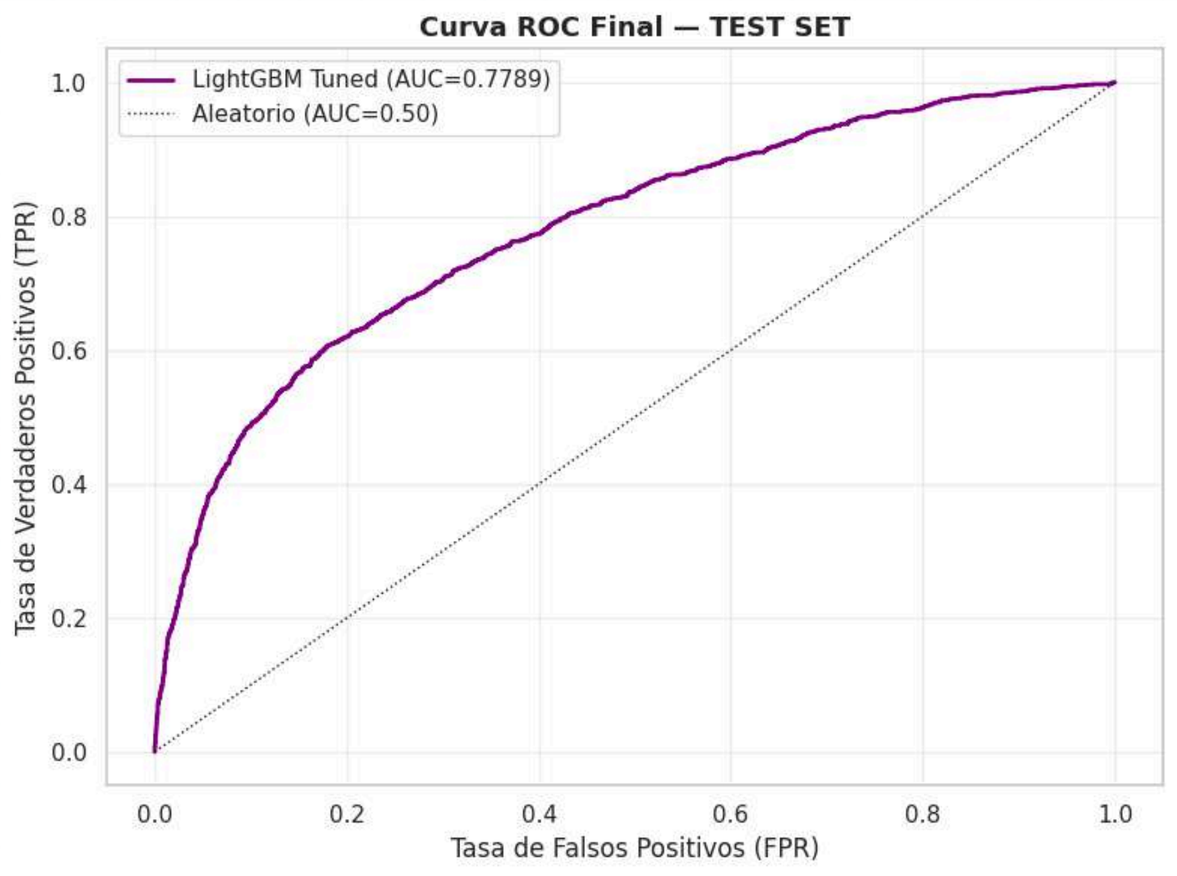

Conclusiones

- El modelo LightGBM optimizado presentó el mejor desempeño tanto en clasificación como en regresión.
- En el problema de clasificación, el modelo detecta aproximadamente 88% de los clientes que entrarán en default, lo que permite anticipar posibles pérdidas crediticias.
- En el problema de regresión, el modelo logró un $R^2 \approx 0.75$, lo que indica una buena capacidad para estimar los montos de pago futuros de los clientes.
- Las variables más predictivas están relacionadas con el historial de pagos, lo que confirma que el comportamiento financiero reciente es un fuerte indicador del riesgo crediticio.
- Los resultados muestran que los modelos de Machine Learning pueden mejorar la evaluación del riesgo crediticio y apoyar la toma de decisiones financieras.

Recomendaciones

- Utilizar el modelo de clasificación para identificar clientes con mayor probabilidad de incumplimiento antes de otorgar crédito.
- Utilizar el modelo de regresión para estimar el flujo de pagos esperado, lo que puede mejorar la planificación financiera y la gestión de cobranza.
- Ajustar el umbral de decisión del modelo según la estrategia de riesgo de la institución financiera.
- Implementar sistemas de credit scoring dinámico, que permitan monitorear el riesgo de los clientes de forma continua.
- Aplicar estrategias de pricing basado en riesgo, ajustando tasas de interés o límites de crédito según la probabilidad de incumplimiento estimada.

¡Gracias!

POR LA ATENCIÓN